École Nationale Supérieure des Mines de Saint-Étienne

Conception d'un Robo-Advisor quantitatif

pour l'allocation dynamique d'actifs
sur l'indice S&P 500

Rapport de Projet Industriel

Auteur : Hugo Munier

Tuteur école : Charbel Al Tannoury

Projet réalisé dans le cadre du cursus MINES Saint-Étienne — Année 2025–2026.

Table des matières

1 Introduction **1**
1.1 Contexte . . . 1
1.2 Enjeu principal : gestion du risque et drawdowns . . . 1
1.3 Objectif du projet . . . 1
1.4 Démarche générale et étapes du travail . . . 1
1.5 Choix méthodologique : détection de régimes de stress . . . 2

2 Contexte et cahier des charges du Robo-Advisor **2**
2.1 Public visé et hypothèses de travail . . . 2
2.2 Objectifs de gestion : Croissance et protection du capital . . . 3
2.3 Contraintes opérationnelles : Frais, fréquence et simplicité . . . 3
2.4 Choix méthodologique : Pourquoi la prédiction directionnelle n'est pas retenue . . . 4

3 Choix de l'Univers d'Investissement **4**
3.1 Dualité technique et psychologique de la sélection . . . 5
3.2 Analyse des relations linéaires des actifs & choix de la stratégie de gestion . 5
3.3 Perspectives : Vers une modélisation non-linéaire des dépendances . . . 7

4 Modélisation de la volatilité : approche économétrique **8**
4.1 L'échec de l'hypothèse de normalité . . . 8
4.2 Modèle économétrique . . . 9
4.2.1 Méthodologie de sélection et processus de Box-Jenkins . . . 9
4.2.2 Premier choix : Le modèle GARCH(1,1) « Pure » . . . 10
4.2.3 Second choix : Le modèle GJR-GARCH . . . 11
4.2.4 Limites et perspectives : Analyse par ruptures structurelles . . . 13
4.3 Limites de l'approche économétrique et pivot vers le Deep Learning . . . 13
4.3.1 Analyse critique de la rigidité des modèles GARCH . . . 14
4.3.2 L'apport du LSTM : Une réponse aux verrous statistiques . . . 14
4.3.3 Supériorité du GARCH comme « Feature » hybride . . . 14

5 Modèle final : LSTM pour classification des régimes de stress **15**
5.1 Architecture du réseau et sélection des descripteurs . . . 15
5.1.1 Ingénierie des variables . . . 15
5.1.2 Structure du réseau et mécanismes d'optimisation . . . 15
5.1.3 Gestion du déséquilibre et logique de décision prudente . . . 16
5.2 Source, périmètre et préparation des données . . . 16
5.3 Analyse des résultats et comparaison des moteurs de volatilité . . . 17
5.3.1 Analyse des performances : Configuration avec moteur GARCH(1,1) 17
5.3.2 Analyse des performances : Configuration avec moteur GJR-GARCH (Asymétrique) . . . 18
5.4 Méthodologie de prédiction : Fenêtrage et anticipation préventive . . . 19
5.4.1 La mécanique du Lookback : Capturer l'ambiance de marché . . . 19
5.4.2 L'anticipation préventive par le décalage temporel (Shift) . . . 20
5.4.3 Analyse opérationnelle des prédictions (2023 - début 2026) - GARCH 20
5.4.4 Analyse opérationnelle des prédictions : Variante GJR-GARCH (2023 - 2026) . . . 21

6 Backtest et Simulation de Performance **23**
6.1 Méthodologie du Backtest et règles d'allocation 23
6.1.1 Configuration de la simulation 23
6.1.2 Règles d'allocation dynamique et compositions cibles 23
6.1.3 Optimisation par Buffer d'Hystérésis via Optuna 23
6.2 Analyse de la performance cumulative et résilience du portefeuille (Modèle GARCH) 24
6.2.1 Dynamique de performance et effet de capitalisation 24
6.2.2 Analyse de la gestion du risque et des drawdowns 25
6.2.3 Efficacité du couplage LSTM-GARCH en conditions réelles 25
6.3 Analyse de la performance cumulative et résilience : Modèle GJR-GARCH 25
6.3.1 Analyse de la performance nette 26
6.3.2 Maîtrise du risque et protection contre les baisses (*Drawdowns*) . . 26
6.3.3 Synthèse : L'avantage de l'asymétrie 27
6.4 Analyse comparative des métriques de performance 27

7 Conclusion générale, limites et perspectives **28**
7.1 Synthèse des contributions 28
7.2 Limites et regard critique sur le modèle 29
7.3 Perspectives et améliorations possibles 29

A Annexe **32**

1 Introduction

1.1 Contexte

Les marchés actions, et en particulier l'indice S&P 500, constituent un support d'investissement privilégié grâce à leur potentiel de croissance à long terme. Toutefois, cette performance s'accompagne d'une exposition importante aux épisodes de stress de marché, caractérisés par une hausse brutale de la volatilité et des baisses rapides des prix. Dans ce contexte, l'automatisation de décisions d'allocation à l'aide de méthodes quantitatives, via un robo-advisor, représente une approche pertinente pour piloter l'exposition au risque de manière systématique.

L'objectif de ce projet industriel est ainsi de proposer un cadre de décision quantitatif permettant d'adapter l'allocation d'un portefeuille centré sur le S&P 500 en fonction des conditions de marché, tout en intégrant des contraintes réalistes telles que les coûts de transaction.

1.2 Enjeu principal : gestion du risque et drawdowns

Au-delà du rendement moyen, la maîtrise du risque constitue un élément central en allocation d'actifs. Les phases de drawdown, définies comme la baisse maximale enregistrée entre un point haut et un point bas, influencent fortement l'évolution de la valeur d'un portefeuille. Une baisse importante nécessite en effet un gain proportionnellement plus élevé pour revenir au niveau initial, ce qui dégrade la performance à long terme et augmente le risque comportemental de désinvestissement au pire moment.

Dans ce projet, la priorité est donc d'améliorer la robustesse du portefeuille face aux phases de stress, en cherchant à limiter les drawdowns et à mieux contrôler le risque extrême, tout en maintenant une exposition suffisante aux phases de croissance du marché.

1.3 Objectif du projet

L'objectif principal est de concevoir un robo-advisor quantitatif capable de piloter l'exposition au S&P 500 à partir d'indicateurs de risque de marché. Concrètement, le système doit : (i) identifier des conditions de marché correspondant à différents niveaux de stress ; (ii) traduire cette information en décisions d'allocation entre un actif risqué et des actifs défensifs ; (iii) intégrer les coûts de transaction afin d'évaluer la performance nette ; et (iv) limiter le turnover via un mécanisme de filtrage afin d'éviter des réallocations inutiles.

La performance de l'approche est évaluée par comparaison avec une stratégie passive de type *buy-and-hold*, à l'aide d'indicateurs classiques tels que la performance cumulée, le maximum drawdown, le ratio de Sharpe et la Value-at-Risk (VaR).

1.4 Démarche générale et étapes du travail

Le projet a été construit de manière itérative, en combinant analyse financière, modélisation statistique et validation par backtesting. Dans un premier temps, une étude est menée afin de sélectionner des actifs défensifs pertinents, capables de jouer un rôle de couverture en période de stress.

Dans un second temps, la modélisation du risque est abordée via des approches économétriques de volatilité conditionnelle (famille GARCH), puis via l'exploration de variables

exogènes telles que le VIX, représentant la volatilité implicite du marché. Ces travaux permettent de mieux comprendre les dynamiques de volatilité et d'évaluer la pertinence de signaux de stress.

Enfin, le projet converge vers une approche de classification permettant d'identifier des régimes de stress. Ce signal pilote une stratégie d'allocation dynamique, enrichie par l'intégration des coûts de transaction et par un mécanisme de bande passante (*buffer*) destiné à limiter les changements d'allocation trop fréquents.

1.5 Choix méthodologique : détection de régimes de stress

Un point clé de ce projet est le choix de ne pas viser la prédiction directionnelle quotidienne des rendements. À cette fréquence, le signal est fortement bruité et conduit souvent à des modèles instables hors échantillon. À l'inverse, la volatilité et le stress de marché présentent des propriétés plus persistantes (*volatility clustering*), rendant leur modélisation plus exploitable pour une prise de décision robuste.

Le problème est donc reformulé en détection de régimes de marché : plutôt que d'estimer un rendement futur, l'objectif est d'identifier des états de marché correspondant à un niveau de stress croissant (calme, nervosité, danger). Cette classification est ensuite utilisée comme variable décisionnelle pour ajuster l'allocation du portefeuille de manière progressive et contrôlée.

2 Contexte et cahier des charges du Robo-Advisor

2.1 Public visé et hypothèses de travail

La conception de ce robo-advisor s'inscrit dans une démarche de démocratisation de l'investissement structuré. L'objectif est de transformer une gestion souvent émotionnelle en une stratégie disciplinée, accessible à un profil d'investisseur spécifique.

Profil de l'investisseur cible
Ce projet est né d'un constat personnel : l'étudiant ou le jeune actif souhaite capitaliser sur le temps long, mais se retrouve souvent démuni face à la volatilité des marchés. Le public visé est donc l'investisseur particulier débutant qui dispose d'un horizon de placement lointain mais d'un temps limité pour le suivi quotidien. Ce profil accepte une exposition significative aux actions pour capter la croissance, mais nécessite un garde-fou méthodologique pour ne pas abandonner sa stratégie lors des retournements de marché.

Le choix du support : la transparence du S&P 500
Le S&P 500 s'est imposé comme l'actif principal de cette stratégie. Indice de référence mondial, il offre une crédibilité immédiate et une liquidité totale, évitant ainsi l'effet « boîte noire » des actifs complexes. Toutefois, l'exposition pure aux actions reste vulnérable aux chocs systémiques. La mission du robo-advisor est donc de concilier la performance historique de cet indice avec un mécanisme de protection active, assurant une trajectoire de croissance plus sereine.

Hypothèses simplificatrices
Pour garantir la reproductibilité du modèle dans un cadre réel pour un particulier, les hypothèses suivantes sont retenues :

— **Univers binaire :** Le portefeuille alterne entre un actif risqué (S&P 500) et des actifs de couverture.
— **Gestion systématique :** Les arbitrages sont déclenchés par des signaux quantitatifs de stress, limitant les biais cognitifs.
— **Réalisme opérationnel :** L'horizon de gestion est compatible avec une fréquence de rebalancement modérée pour minimiser les coûts de transaction.

2.2 Objectifs de gestion : Croissance et protection du capital

L'ambition du robo-advisor n'est pas de prédire le marché, mais de réagir intelligemment à son niveau de risque. Cette approche repose sur une logique de gestion « risk-on / risk-off » structurée.

Une allocation dynamique et réactive
L'idée centrale est d'ajuster le curseur d'exposition en fonction des indicateurs de stress. En régime de croisière, l'allocation maximise l'exposition au S&P 500. Dès l'apparition de turbulences, la stratégie réduit cette exposition pour renforcer la composante défensive. Cette transition progressive permet de limiter l'impact des chocs de volatilité tout en restant à proximité du marché pour capter les éventuels rebonds rapides.

Indicateurs de performance et de risque
Pour valider la robustesse de cette trajectoire, le succès de la stratégie sera mesuré à l'aide d'un tableau de bord multidimensionnel :
— **Performance ajustée :** Utilisation du ratio de Sharpe pour vérifier que le rendement obtenu justifie le risque pris.
— **Contrôle du risque extrême :** Analyse du *Maximum Drawdown* et de la *Value-at-Risk* (VaR) pour évaluer la protection réelle du capital lors des pires scénarios.
— **Stabilité :** Mesure de la volatilité globale pour garantir un confort psychologique à l'investisseur.

2.3 Contraintes opérationnelles : Frais, fréquence et simplicité

Pour garantir la viabilité du robo-advisor dans un environnement réel, la stratégie intègre des contraintes opérationnelles majeures. L'objectif est de transformer un modèle théorique en une solution d'investissement pragmatique.

Optimisation des coûts et du turnover
La première contrainte réside dans les frais de transaction. Une stratégie trop active, réagissant au moindre « bruit » de marché, verrait sa performance nette érodée par les commissions de courtage. Le modèle est donc conçu pour limiter le *turnover* (rotation du portefeuille) en privilégiant des signaux de stress persistants plutôt que des micro-ajustements quotidiens.

Fréquence de réallocation et réalisme pratique
Bien qu'une surveillance quotidienne soit nécessaire pour la détection des krachs, la fréquence de réallocation effective doit rester compatible avec la gestion d'un investisseur

particulier. Une réactivité excessive engendre souvent une instabilité émotionnelle et financière. Le projet adopte donc une approche dynamique mais contrôlée, visant un équilibre entre réactivité face au risque et stabilité de l'allocation.

Simplicité et transparence du produit
Enfin, la simplicité est érigée en règle de gestion. Pour l'investisseur cible, la compréhension du signal de stress et du mécanisme d'allocation est primordiale. L'évitement de la complexité mathématique inutile garantit une évaluation transparente lors du *backtest* et renforce la confiance de l'utilisateur dans les décisions prises par l'algorithme.

2.4 Choix méthodologique : Pourquoi la prédiction directionnelle n'est pas retenue

Une approche classique consisterait à tenter de prédire la direction du marché (hausse ou baisse). Ce projet rejette explicitement cette voie au profit d'une gestion basée sur le risque.

L'instabilité des prévisions de rendement
À court terme, les rendements financiers sont caractérisés par un niveau de bruit extrêmement élevé. Tenter de prédire si le S&P 500 sera en hausse ou en baisse le lendemain est un exercice périlleux qui conduit souvent à des signaux contradictoires et à une suractivité coûteuse. Une erreur de prévision directionnelle peut s'avérer bien plus pénalisante pour la performance nette qu'une gestion de risque prudente.

La volatilité comme signal robuste
Contrairement aux rendements, la volatilité et les phases de stress présentent des propriétés de « persistance » (phénomène de *volatility clustering*). Lorsqu'un régime de stress s'installe, il a tendance à durer.

En période de forte volatilité, les marchés sont dominés par l'aversion au risque et les comportements grégaires, rendant les prévisions directionnelles encore moins fiables.

Détection de régime vs Anticipation
Le choix méthodologique est donc clair : nous ne cherchons pas à anticiper le rendement futur, mais à détecter le régime de risque actuel. En ajustant l'exposition au S&P 500 selon un niveau de stress estimé, le robo-advisor adopte une posture défensive dès que l'incertitude devient critique, assurant ainsi une protection du capital bien plus stable et robuste qu'une stratégie fondée sur la spéculation directionnelle.

3 Choix de l'Univers d'Investissement

La construction de l'univers d'investissement constitue le socle de notre stratégie de couverture. Ce choix ne s'est pas limité à une simple sélection d'actifs décorrélés sur longue période ; il a nécessité une analyse fine de la dynamique des relations entre classes d'actifs, notamment lors des changements de régime économique. Notre approche repose sur la volonté de concilier une efficacité mathématique rigoureuse avec une lisibilité psychologique indispensable pour l'investisseur.

3.1 Dualité technique et psychologique de la sélection

La définition de l'univers d'investissement ne peut se limiter à une simple optimisation de la frontière efficiente. Pour qu'une stratégie de couverture soit réellement efficace, elle doit répondre à une double exigence : une rigueur mathématique garantissant la protection du capital, et une clarté psychologique assurant l'adhésion de l'investisseur final.

L'impératif technique : Corrélation et Liquidité
D'un point de vue purement quantitatif, le premier critère de sélection est la recherche d'une corrélation négative (ou au moins d'une forte décorrélation) par rapport à l'indice de référence, le S&P 500. L'objectif est de s'assurer que les actifs choisis agissent comme des stabilisateurs lors des phases de correction de marché. Cette capacité de couverture doit impérativement s'accompagner d'une liquidité de marché élevée. En effet, un instrument de couverture n'est utile que s'il peut être arbitré rapidement et sans décalage de prix important, même en période de stress systémique.

Le facteur humain : Transparence et Confiance
Cependant, la performance théorique se heurte souvent à la psychologie de l'investisseur. Un portefeuille composé d'instruments trop complexes ou opaques peut générer un « effet boîte noire » anxiogène. Pour éviter cela, nous avons privilégié des actifs refuges ancrés dans l'imaginaire collectif et dont les fondamentaux sont intelligibles par le grand public. La lisibilité du portefeuille est ici considérée comme un outil de gestion des risques à part entière : un investisseur qui comprend pourquoi ses actifs réagissent d'une certaine manière est moins enclin à prendre des décisions émotionnelles irrationnelles lors d'une baisse.

La sélection retenue : Le binôme TLT / GLD
À la croisée de ces deux chemins, le choix s'est porté sur deux piliers historiques : les obligations d'États amércains à long terme (TLT) et l'or (GLD).

- **Le TLT** offre une réponse technique robuste grâce à sa tendance historique à s'apprécier lors des krachs boursiers et sa liquidité profonde.
- **Le GLD** remplit le rôle d'actif tangible et rassurant, protégeant contre les risques inflationnistes ou de dévaluation monétaire, tout en étant universellement reconnu comme une réserve de valeur.

Cette alliance permet de concilier la performance mathématique du modèle avec une sérénité psychologique indispensable à la tenue de la stratégie dans le temps.

3.2 Analyse des relations linéaires des actifs & choix de la stratégie de gestion

L'efficacité d'une stratégie de couverture repose sur la stabilité des relations linéaires entre l'actif risqué et ses protecteurs. Une analyse approfondie des corrélations sous différents régimes de marché permet de justifier le passage d'une gestion statique à une stratégie adaptative.

L'attrait historique et théorique du TLT
D'un point de vue quantitatif, le premier critère de sélection est la recherche d'une corrélation négative par rapport au S&P 500. Le TLT (Obligations d'État à long terme)

semble être un candidat idéal : comme le montre le graphique ci-dessous, sa corrélation reste négative à travers tous les régimes de volatilité, ce qui est particulièrement attrayant pour stabiliser un portefeuille au quotidien.

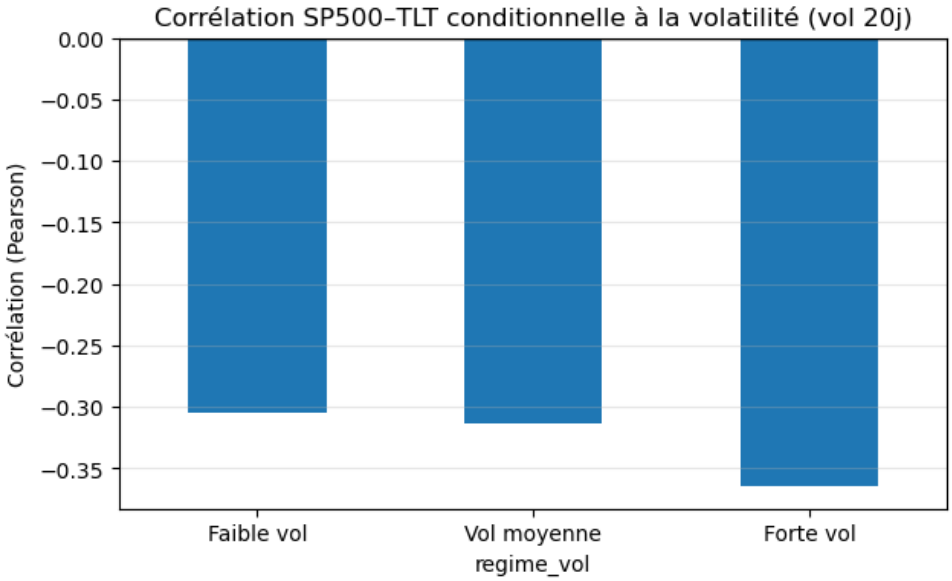

FIGURE 1 – Corrélation SP500–TLT conditionnelle à la volatilité

Historiquement, les obligations d'État agissent comme un actif de refuge lors des baisses du S&P 500. Souvent, l'effet sur les obligations était une augmentation de leur prix accompagnée d'une baisse des intérêts. Cependant, à la suite du COVID, ce mécanisme s'est grippé : la chute du S&P 500 a coïncidé avec une hausse des taux d'intérêt (due à l'inflation), entraînant une baisse brutale du prix des obligations. En regardant la corrélation en fonction du drawdown, on comprend que le TLT est fortement influencé par l'ampleur de la baisse du marché actions.

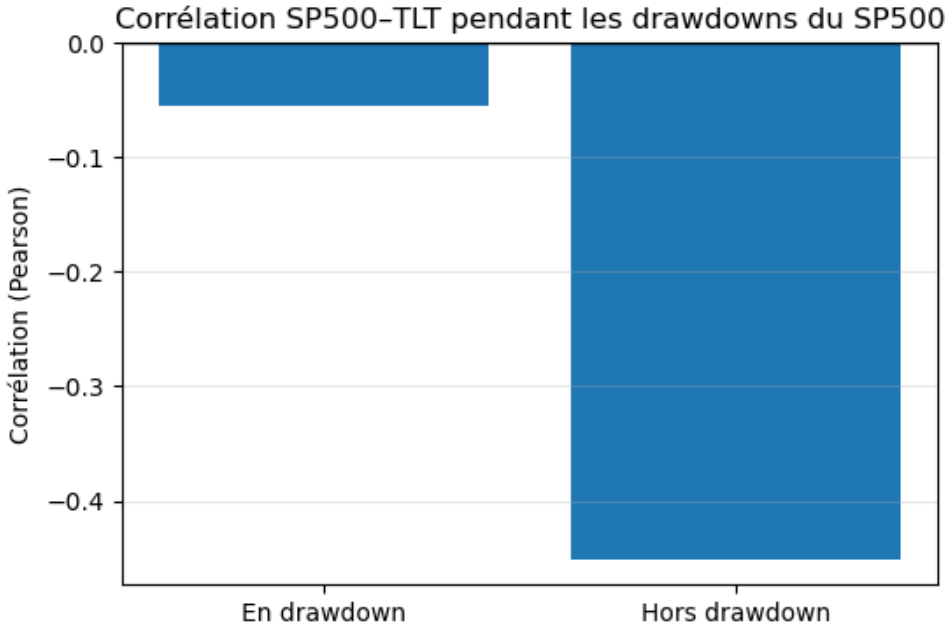

FIGURE 2 – Corrélation SP500–TLT en fonction du niveau de drawdown

L'Or : L'alternative pour les phases de stress extrême
Face à cette instabilité du TLT dans les moments critiques, nous nous sommes intéressés à l'Or (GLD). L'analyse montre que l'Or est globalement insensible aux différents niveaux de stress ou de baisse du S&P 500. Sa corrélation reste proche de zéro, peu importe le régime de volatilité ou l'intensité de la chute du marché.

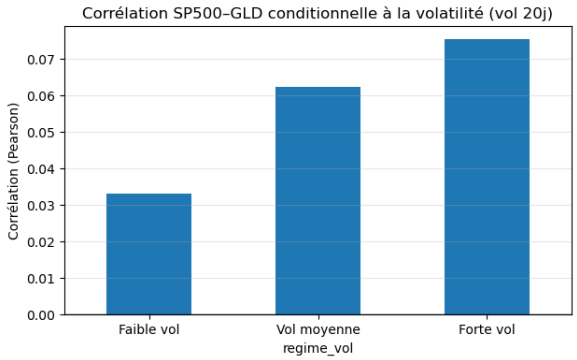

FIGURE 3 – Corrélation GLD vs Volatilité

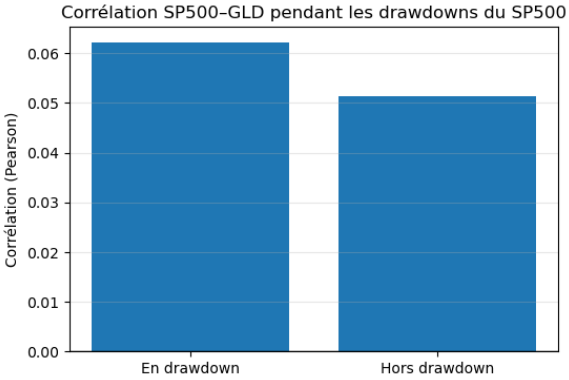

FIGURE 4 – Corrélation GLD vs Drawdown

Logique algorithmique retenue
Cette analyse nous mène à une stratégie de gestion hybride : il est plus intéressant d'utiliser le TLT dans une phase plus « nerveuse » (fluctuations quotidiennes) pour amortir les petites baisses du S&P 500. En revanche, dans les phases à grand risque (stress extrême), il devient crucial d'investir une partie du capital sur l'Or, car il offre une décorrélation bien plus fiable lorsque les actifs traditionnels tendent à chuter ensemble.

3.3 Perspectives : Vers une modélisation non-linéaire des dépendances

Bien que l'analyse des corrélations linéaires (Pearson) et leur observation sous différents régimes de volatilité fournissent une base solide pour notre stratégie, il convient de souligner les limites inhérentes à cette approche. En finance, les relations entre actifs sont rarement constantes et présentent souvent des comportements non-linéaires complexes, particulièrement lors des crises systémiques.

Les limites de la corrélation classique
La corrélation de Pearson, utilisée dans les parties précédentes, mesure la force d'une relation linéaire moyenne. Elle ne permet pas de capturer la dépendance de queue, ce phénomène où des actifs décorrélés en temps normal chutent simultanément lors d'un krach boursier. L'instabilité du TLT observée précédemment est une manifestation de cette non-linéarité : la structure de dépendance change radicalement selon l'état du marché.

Pistes d'amélioration : Copules et Changements de Régime
Une analyse plus poussée, que nous n'avons pas implémentée dans le cadre de ce rapport mais qui constituerait une évolution majeure, reposerait sur deux piliers :

— **Les Copules :** Cet outil mathématique permet de modéliser la structure de dépendance de manière isolée des rendements individuels. Elles sont particulièrement efficaces pour quantifier la probabilité que le S&P 500 et le TLT échouent à se protéger mutuellement lors d'événements extrêmes.
— **Les modèles à changement de régime (Markov Switching) :** Plutôt que d'ajuster une corrélation fixe, ces modèles identifient mathématiquement des « états » de marché (ex : régime de croissance vs régime de crise inflationniste).

En conclusion, bien que nous ayons opté pour une approche adaptative basée sur des seuils de volatilité la reconnaissance de ces dynamiques non-linéaires justifie d'autant plus notre choix d'inclure l'Or. Le GLD agit ici comme une assurance contre les failles des modèles linéaires traditionnels, offrant une protection là où les mathématiques de corrélation standard atteignent leurs limites.

4 Modélisation de la volatilité : approche économétrique

4.1 L'échec de l'hypothèse de normalité

Avant d'entamer la modélisation de la volatilité, il est impératif d'étudier la distribution statistique des rendements du S&P 500. En finance classique, l'utilisation de la loi normale est courante pour sa simplicité mathématique. Cependant, la confrontation de cette hypothèse aux données réelles révèle des divergences critiques.

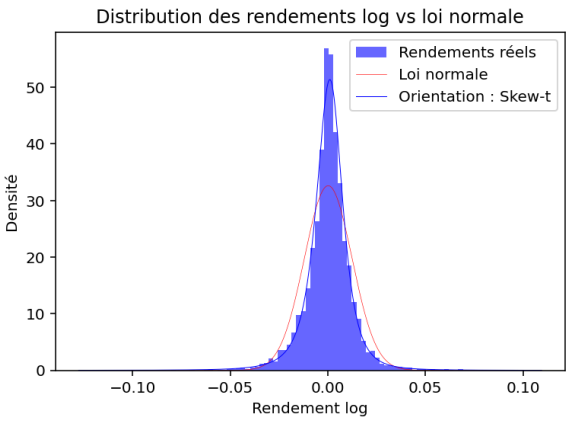

FIGURE 5 – Distribution des rendements log vs Loi normale

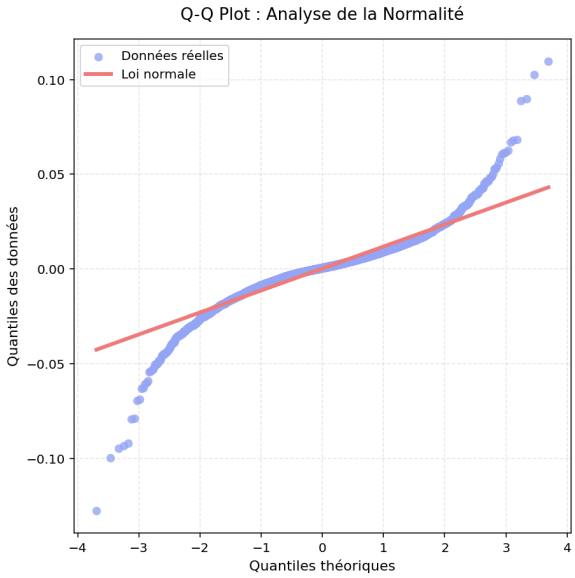

FIGURE 6 – Q-Q Plot : Analyse de la Normalité

L'observation combinée de l'histogramme des rendements et du graphique Q-Q Plot permet de mettre en évidence les propriétés réelles du marché, souvent ignorées par les modèles standards :

La Leptokurtose (Queues épaisses)
L'histogramme montre une concentration des rendements autour de la moyenne plus élevée

que prévu, mais surtout des extrémités (« queues ») beaucoup plus étalées. Le Q-Q Plot confirme visuellement ce phénomène : aux deux extrémités, les points bleus (données réelles) s'éloignent radicalement de la droite rouge (loi normale). Cela signifie que les événements extrêmes, tels que les krachs boursiers, surviennent avec une fréquence bien plus élevée que ce qu'un modèle gaussien prédit.

L'asymétrie des rendements
Les données révèlent une asymétrie marquée : les pertes extrêmes sont plus fréquentes et souvent plus brutales que les gains de même ampleur. Sur le Q-Q Plot, la déviation est particulièrement prononcée dans la zone des quantiles négatifs, soulignant une vulnérabilité critique du S&P 500 aux mouvements baissiers violents.

Un enjeu majeur
Ignorer ces « queues épaisses » expose le portefeuille à un risque de ruine lors d'événements extrêmes, souvent qualifiés de « Cygnes Noirs ». En finance de marché, sous-estimer la probabilité de ces krachs revient à construire une stratégie fragile qui échouera précisément au moment où la protection est la plus nécessaire.

Cette analyse préliminaire démontre que la volatilité ne peut être traitée comme un paramètre statique. Elle nécessite une approche capable de capturer cette dynamique et la persistance des chocs, justifiant ainsi l'utilisation de modèles économétriques plus avancés.

4.2 Modèle économétrique

4.2.1 Méthodologie de sélection et processus de Box-Jenkins

La construction de notre modèle de volatilité repose sur une approche rigoureuse inspirée de la méthodologie de Box-Jenkins, appliquée sur une période étendue allant de 2000 à 2024. Cette fenêtre temporelle est cruciale car elle englobe des régimes de marché radicalement différents, incluant la crise financière de 2008 et le choc pandémique du COVID-19, permettant ainsi d'éprouver la robustesse des modèles face à des pics de stress extrêmes.

Étape 1 : Nettoyage et identification
Après nettoyage du jeu de données, nous avons procédé à l'analyse des propriétés statistiques des rendements. L'objectif était d'identifier la présence d'autocorrélation dans les rendements (processus ARMA) et d'hétéroscédasticité conditionnelle (effets ARCH).

Étape 2 : L'échec des modèles avec composante moyenne
Dans un premier temps, nous avons testé plusieurs spécifications combinant une équation de la moyenne (AR, MA, ARMA avec divers paramètres) et une équation de la variance. Bien que le modèle **MA(1)-GARCH** ait semblé initialement performant, les tests de diagnostic ont révélé des faiblesses importantes :

— **Test de Ljung-Box :** Présence d'autocorrélation résiduelle significative.

Le maintien d'une structure de corrélation dans les résidus indique que le modèle ne parvient pas à blanchir totalement l'information, rendant les prévisions de volatilité potentiellement biaisées.

Étape 3 : Vers des modèles « purs » et sélection finale
Pour pallier ce problème, nous avons pris le parti de modéliser directement la variance sans composante moyenne (modèles « purs »). Cette décision s'appuie sur le fait que, sur un horizon quotidien, l'espérance des rendements est statistiquement proche de zéro, et l'ajout d'un processus ARMA peut parfois introduire plus de bruit que de précision.

Nous avons ainsi comparé une vaste famille de modèles pour capturer les faits stylisés (asymétrie, persistance) : **ARCH, GARCH, EGARCH** et **GJR-GARCH**. Suite à cette phase de test comparative, nous avons retenu deux modèles qui feront l'objet d'une analyse détaillée dans la suite de ce rapport, car ils présentent les résidus les plus stables.

4.2.2 Premier choix : Le modèle GARCH(1,1) « Pure »

Le premier modèle sélectionné est le GARCH (*Generalized Autoregressive Conditional Heteroskedasticity*), pilier de l'économétrie financière. Contrairement à une estimation de volatilité historique simple, le modèle GARCH traite la variance comme un processus dynamique qui dépend à la fois des chocs passés et de sa propre histoire.

Définition mathématique
Nous utilisons une spécification GARCH(1,1) « pure », sans équation de la moyenne, où les rendements log r_t sont modélisés par :

$$r_t = \sigma_t \epsilon_t \tag{1}$$

L'équation de la variance conditionnelle σ_t^2 s'écrit alors :

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \tag{2}$$

Où $\omega > 0$, $\alpha \geq 0$, $\beta \geq 0$ et $(\alpha + \beta) < 1$ pour garantir la stationnarité du processus. Cette structure permet de capturer efficacement le phénomène de regroupement de la volatilité (*volatility clustering*).

Analyse empirique et parcimonie
Le choix d'un modèle « Pure » (sans composante ARMA pour la moyenne) a été dicté par une recherche de parcimonie et de stabilité numérique. L'ajout d'une moyenne complexe augmentait en effet l'autocorrélation résiduelle au lieu de l'atténuer. Comme illustré dans la Figure 7, le modèle parvient à suivre avec une grande précision la volatilité historique tout en offrant une estimation réactive lors des chocs majeurs de la période 2000-2024.

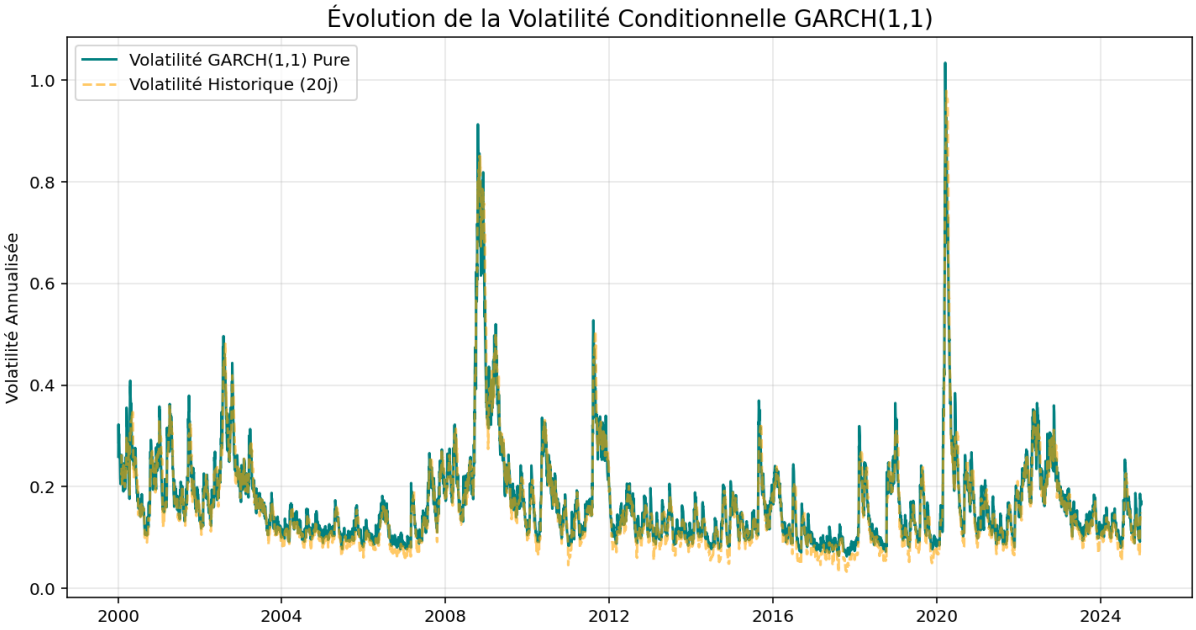

FIGURE 7 – Évolution de la Volatilité Conditionnelle GARCH(1,1) vs Historique

Diagnostics statistiques et limites
Le tableau suivant résume les performances du modèle lors des tests de diagnostic sur les résidus. Bien qu'il subsiste une légère autocorrélation résiduelle (indiquée par les p-values du test de Ljung-Box inférieures à 0,05), ce modèle est celui qui présente la structure linéaire la plus acceptable parmi toutes les architectures testées pour ces données.

Test de Diagnostic	**Lag 10 (p-value)**	**Lag 20 (p-value)**
Ljung-Box (Autocorrélation)	0,025	0,041
ARCH-LM (Hétéroscédasticité)	0,270	0,310

TABLE 1 – Diagnostics des résidus pour le modèle GARCH(1,1)

L'analyse du test ARCH-LM est particulièrement satisfaisante : avec des p-values de 0,27 et 0,31 (nettement supérieures au seuil de 5 %), nous pouvons affirmer que la dynamique de la volatilité est totalement absorbée. Cela signifie que le modèle a parfaitement extrait l'information contenue dans la variance, faisant du GARCH(1,1) un premier moteur robuste pour notre signal de stress.

4.2.3 Second choix : Le modèle GJR-GARCH

Bien que le modèle GARCH(1,1) soit performant, il impose une réponse symétrique de la volatilité aux chocs de rendement. Or, nous avons observé lors de l'étude de la non-normalité que les pertes extrêmes induisent souvent une panique bien plus violente que les gains de même ampleur. Pour capturer cet « effet de levier », nous avons retenu le modèle GJR-GARCH (*Glosten-Jagannathan-Runkle*).

Définition mathématique
Le modèle GJR-GARCH(1,1) introduit un paramètre d'asymétrie γ qui s'active spécifi-

quement lors des chocs négatifs. L'équation de la variance conditionnelle s'écrit :

$$\sigma_t^2 = \omega + \alpha\epsilon_{t-1}^2 + \gamma I_{t-1}\epsilon_{t-1}^2 + \beta\sigma_{t-1}^2 \tag{3}$$

Où I_{t-1} est une fonction indicatrice (dummy variable) valant 1 si $\epsilon_{t-1} < 0$ (rendement négatif) et 0 sinon. Si $\gamma > 0$, l'impact d'une nouvelle négative sur la volatilité future est supérieur à celui d'une nouvelle positive, traduisant une sensibilité accrue aux phases de baisse.

Analyse empirique : Précision du risque extrême
Comme illustré dans la Figure 8, le GJR-GARCH offre une lecture plus nerveuse et précise des pics de stress. Cette capacité d'anticipation est un atout majeur pour détecter les phases de panique boursière, permettant au robo-advisor de réagir plus précocement lors des retournements de tendance.

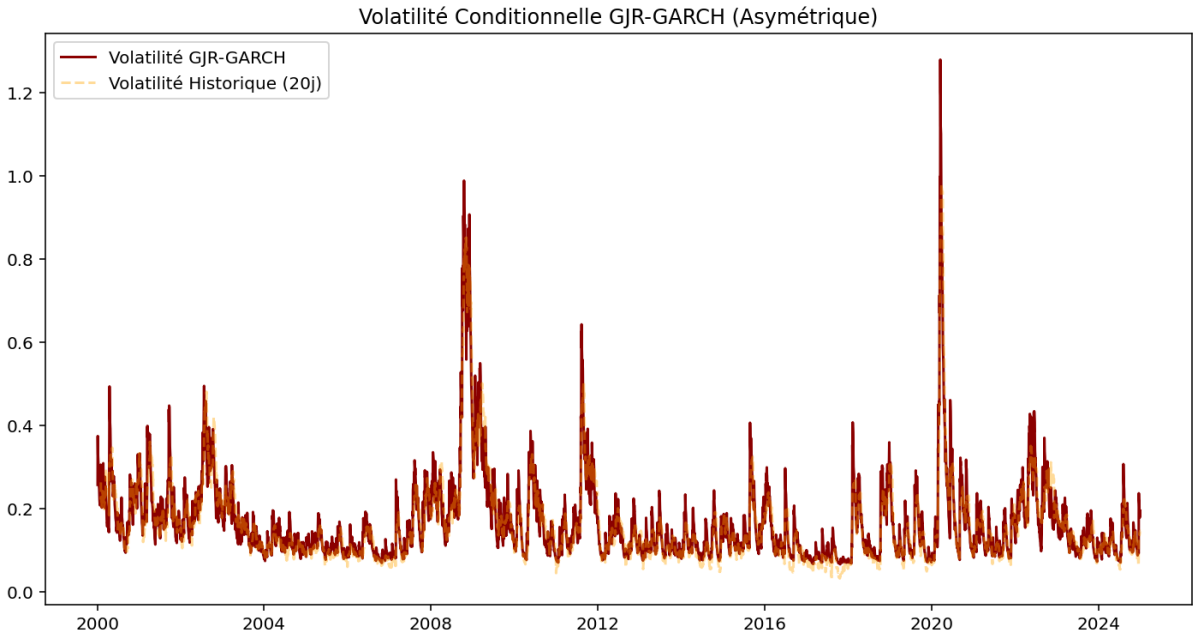

FIGURE 8 – Volatilité Conditionnelle GJR-GARCH(1,1) : Sensibilité accrue aux chocs négatifs

Diagnostics statistiques et élimination de l'hétéroscédasticité
Le tableau suivant résume les tests de validation effectués sur les résidus du modèle GJR-GARCH :

Test de Diagnostic	**Lag 10 (p-value)**	**Lag 20 (p-value)**
Ljung-Box (Autocorrélation)	0,042	0,069
ARCH-LM (Hétéroscédasticité)	0,590	0,660

TABLE 2 – Diagnostics des résidus pour le modèle GJR-GARCH(1,1)

L'analyse de ces résultats met en évidence deux points fondamentaux :

— **Information linéaire :** Les p-values de Ljung-Box se stabilisent au-dessus du seuil de 5 % à partir du Lag 20, indiquant que l'essentiel de l'information linéaire a été traité.

— **Succès de la modélisation du risque :** Les p-values exceptionnelles du test ARCH-LM (0,59 et 0,66) démontrent une élimination quasi-totale de l'hétéroscédasticité conditionnelle. La dynamique de la volatilité est entièrement absorbée par le modèle.

Ce second choix apporte la précision nécessaire pour la gestion du risque extrême, complétant ainsi notre moteur économétrique par une prise en compte de l'asymétrie comportementale des marchés.

4.2.4 Limites et perspectives : Analyse par ruptures structurelles

Bien que les modèles GARCH et GJR-GARCH sur la période 2000-2024 offrent une vision robuste et moyennée des dynamiques de marché, l'autocorrélation résiduelle observée précédemment souligne une limite intrinsèque à l'estimation sur échantillon long.

L'instabilité des paramètres temporels
L'une des hypothèses fortes de notre modélisation est la constance des paramètres (ω, α, β) sur plus de deux décennies. Or, la structure de la volatilité du S&P 500 évolue au gré des changements de paradigmes géopolitiques et monétaires. Estimer un modèle unique sur une période incluant la bulle internet, l'ère des taux zéro et le retour de l'inflation post-COVID induit nécessairement un biais de spécification.

Piste d'amélioration : Le découpage par mandats et crises
Une extension naturelle de ce travail, que nous n'avons pu implémenter par contrainte de temps, consisterait à segmenter l'analyse sur des sous-périodes cohérentes. Cette approche permettrait de capturer plus finement l'autocorrélation en isolant des contextes spécifiques tels que :

— **Les cycles politiques :** Comparer la dynamique de volatilité sous différents mandats (ex : l'administration Trump, marquée par une communication directe influençant les marchés).

— **Les ruptures de régime :** Distinguer les phases de « grande modération » des périodes de crises systémiques (2008, COVID-19).

Vers des modèles à paramètres changeants
Cette segmentation permettrait d'affiner le signal de stress en adaptant les seuils de bascule à la « nouvelle normale » de chaque époque. Cette piste de réflexion confirme que la modélisation économétrique est un processus itératif, où la précision du signal gagne à être confrontée à la réalité changeante de l'histoire macroéconomique.

4.3 Limites de l'approche économétrique et pivot vers le Deep Learning

Bien que les modèles de la famille GARCH constituent une avancée majeure par rapport à la volatilité historique, leur utilisation en tant que signal décisionnel unique se heurte à des verrous structurels inhérents à la statistique classique. L'approche économétrique, par sa nature paramétrique, impose en effet une rigidité mathématique qui peine à épouser la complexité des marchés financiers.

4.3.1 Analyse critique de la rigidité des modèles GARCH

La première limite fondamentale réside dans la forme fonctionnelle imposée par le modèle. Le GARCH suppose que la relation entre la variance passée et la variance future suit une équation linéaire prédéfinie. Or, la dynamique du S&P 500 est intrinsèquement non-linéaire : la réaction des investisseurs à un choc n'est pas simplement proportionnelle à son intensité, mais dépend de seuils psychologiques et d'effets de rétroaction que des coefficients statiques comme α et β ne peuvent capturer.

Par ailleurs, ces modèles souffrent d'une « mémoire courte » et d'une hypothèse de stationnarité parfois déconnectée de la réalité. En accordant un poids géométriquement décroissant aux chocs passés, le GARCH oublie rapidement les crises structurelles au profit du bruit récent. Cette incapacité à gérer les ruptures de régime, où les règles du jeu changent instantanément lors d'un krach, limite son pouvoir prédictif sur échantillon long. Enfin, sa nature univariée constitue son plus grand défaut : en ne regardant que l'historique des prix, le GARCH ignore les signaux exogènes cruciaux comme les tensions obligataires ou le sentiment de marché.

4.3.2 L'apport du LSTM : Une réponse aux verrous statistiques

Le réseau de neurones récurrent de type LSTM (Long Short-Term Memory) intervient précisément pour lever ces barrières. Contrairement au GARCH, le LSTM dispose d'une architecture capable de maintenir une mémoire sélective et persistante. Grâce à ses « portes » (*gates*) de contrôle, il peut décider quelle information historique — comme une configuration de crise spécifique — doit être conservée sur le long terme et quel bruit de court terme doit être ignoré.

En tant que modèle non-paramétrique, le LSTM agit comme un approximateur universel de fonctions. Il n'impose aucune structure mathématique rigide mais « apprend » la forme de la non-linéarité directement dans les données. Cette flexibilité lui permet de s'adapter aux changements de régime et d'intégrer une dimension multivariée, ingérant simultanément des indicateurs techniques, macroéconomiques et statistiques pour forger une vision globale du risque.

4.3.3 Supériorité du GARCH comme « Feature » hybride

Le pivot stratégique de notre travail réside toutefois dans une approche hybride, consistant à injecter les diagnostics du GARCH comme entrées (*features*) du LSTM plutôt que d'utiliser une simple volatilité moyenne sur 20 jours. L'intérêt est ici de fournir au réseau une information conditionnelle plutôt que simplement retardée. Alors qu'une moyenne mobile lisse les données et réagit avec un décalage temporel souvent préjudiciable, le GARCH estime une volatilité instantanée qui renseigne le modèle sur le risque.

En transmettant les coefficients de persistance et de choc au LSTM, on lui permet de distinguer immédiatement un mouvement erratique sans importance d'un véritable changement de régime de volatilité. L'ajout spécifique du GJR-GARCH permet en outre d'injecter la connaissance de l'asymétrie des chocs (l'effet de levier) directement dans le réseau. Le LSTM n'a ainsi pas besoin de redécouvrir par lui-même que les baisses génèrent plus de panique que les hausses ; il utilise cette règle financière pré-optimisée comme un socle, ce qui accélère sa convergence et accroît significativement la précision du signal de stress final.

5 Modèle final : LSTM pour classification des régimes de stress

5.1 Architecture du réseau et sélection des descripteurs

La force de notre modèle réside dans une approche hybride qui fusionne la rigueur statistique de l'économétrie et la flexibilité prédictive du Deep Learning. Nous avons structuré le réseau pour traiter des variables hétérogènes, avec pour objectif de classifier l'état de nervosité du marché à un horizon d'anticipation de deux jours ($J + 2$).

5.1.1 Ingénierie des variables

Le vecteur d'entrée mobilise trois familles de descripteurs. Les rendements logarithmiques captent la tendance, tandis que le RSI (*Relative Strength Index*) identifie les zones de surchauffe ou de capitulation du momentum. Cet indicateur technique borne la force du marché sur une échelle de 0 à 100 : un niveau élevé signale une "surchauffe" (surachat) où le risque de retournement baisse augmente, tandis qu'un niveau bas indique une "panique" (survente) potentielle.

À cela s'ajoute le VIX, souvent qualifié d'indice de la peur, qui mesure la volatilité implicite. Contrairement à nos modèles GARCH, qui extraient la volatilité réalisée en se basant sur le risque passé (les variations de prix déjà survenues), le VIX est un indicateur prospectif. Il est calculé à partir du prix des options sur le S&P 500 et reflète le coût que les investisseurs sont prêts à payer pour s'assurer contre une baisse future du marché à un horizon de 30 jours.

Une interrogation centrale lors de la conception concernait la redondance potentielle entre le VIX et le GARCH, car ces deux indicateurs traitent de la volatilité. Cependant, ils apportent des éclairages distincts : là où le GARCH est une mesure rétrospective basée sur les faits, le VIX est une projection prospective basée sur le prix des options. Pour éviter que le modèle ne soit confus par des signaux qui se chevauchent temporellement, nous comptons sur la structure interne du LSTM. Ses « portes d'oubli » (*forget gates*) lui permettent de filtrer les corrélations inutiles pour ne conserver que l'information marginale la plus pertinente. Cette sélectivité est renforcée par un *Dropout* de 0,4, qui empêche le réseau de devenir trop dépendant d'un seul indicateur, garantissant ainsi une meilleure généralisation sur des données inconnues.

5.1.2 Structure du réseau et mécanismes d'optimisation

L'architecture du réseau est conçue pour une extraction progressive de la complexité, transformant des signaux financiers bruts en probabilités de décision. Une couche de *BatchNormalization* assure d'abord la stabilité numérique en normalisant les entrées, facilitant ainsi un apprentissage homogène et rapide. Le cœur du modèle repose sur une double couche de neurones LSTM (32 et 16 unités), une hiérarchie qui permet de distinguer les tendances de fond des retournements brutaux de court terme.

À la suite de cette extraction temporelle, nous injectons les informations dans une couche Dense activée par la fonction ReLU (*Rectified Linear Unit*). Le choix de ReLU est stratégique : en annulant les valeurs négatives, elle introduit une non-linéarité parcimonieuse qui aide le modèle à ignorer le bruit de fond sans importance pour ne se concentrer que sur les signaux de stress significatifs. De plus, elle permet de lutter contre le problème de disparition du gradient, garantissant que les couches profondes continuent d'apprendre

efficacement. Enfin, une couche de sortie associée à une fonction Softmax distribue les probabilités sur nos trois régimes : normal, nerveux et extrême.

Pour l'entraînement, nous utilisons l'optimiseur *Adam*, dont le taux d'apprentissage adaptatif est idéal pour naviguer dans l'instabilité des séries financières. Nous avons fixé la limite à 100 époques avec un mécanisme d'*EarlyStopping* pour stopper l'apprentissage dès que la performance sur le *Validation Split* (15 % des données) cesse de s'améliorer, évitant ainsi que le modèle ne mémorise le bruit spécifique du passé au lieu d'apprendre des motifs réutilisables.

5.1.3 Gestion du déséquilibre et logique de décision prudente

Un défi majeur en finance réside dans la rareté statistique des crises, ce qui rend leur détection particulièrement complexe. Pour y répondre, nous avons pris l'initiative d'établir une séparation des régimes basée sur une analyse empirique des distributions de rendement. Nous avons ainsi fixé le seuil de « Danger » aux 15 % des événements les plus extrêmes de l'historique, tandis que le régime « Nerveux » est déclenché dès le quantile 65 %.

Cette segmentation personnalisée permet de cibler précisément les phases de rupture, mais elle crée un déséquilibre de classes que le modèle pourrait avoir tendance à ignorer. Pour compenser ce phénomène, nous avons implémenté des *Class Weights* (poids de classes) lors de l'entraînement. Cette technique pénalise plus lourdement une erreur commise sur un régime de crise qu'une erreur sur un régime calme, forçant ainsi le LSTM à maintenir une vigilance accrue face aux signaux de stress identifiés par nos quantiles.

Enfin, la transformation de la sortie du modèle en décision d'investissement ne repose pas sur une simple probabilité maximale, mais sur des seuils de prudence stricts établis de manière empirique. Pour sécuriser l'allocation, nous avons choisi de n'activer le signal de « Danger » que si sa probabilité dépasse 0,5, privilégiant ainsi la protection absolue du capital au prix d'une sélectivité accrue.

Le régime de « Nervosité », quant à lui, est déclenché dès le seuil de 0,4. Cette calibration, issue de nos tests sur les données historiques, permet d'anticiper la montée de la volatilité moyenne avant que le stress ne devienne systémique. Cette logique de décision asymétrique, dictée par l'observation des comportements passés du modèle, permet au robo-advisor de rester exposé au marché en temps normal tout en étant capable de se désengager massivement dès les premiers signes de rupture.

5.2 Source, périmètre et préparation des données

La phase empirique repose sur la collecte de données financières via l'API Yahoo Finance, couvrant une période allant de janvier 2010 à début 2026. L'utilisation d'une source unique via le même environnement de collecte garantit une cohérence structurelle dès l'extraction des séries temporelles.

Un travail de nettoyage a été nécessaire pour harmoniser ces différentes sources, notamment pour supprimer les valeurs manquantes, et à appliquer un réalignement indiciel sur l'ensemble du dataset. Cette préparation est indispensable pour garantir la fiabilité des résultats lors de la simulation de gestion de portefeuille.

5.3 Analyse des résultats et comparaison des moteurs de volatilité

Pour valider la pertinence de notre architecture hybride, nous avons soumis le modèle à une phase de test rigoureuse en comparant l'efficacité des deux variantes de moteurs de volatilité (GARCH vs GJR-GARCH). L'objectif est d'évaluer la capacité du réseau à identifier les régimes critiques tout en minimisant les faux signaux.

5.3.1 Analyse des performances : Configuration avec moteur GARCH(1,1)

L'évaluation de cette première variante repose sur la confrontation entre les prédictions du modèle LSTM et la réalité des régimes de marché observés. Cette analyse permet de valider la capacité du réseau à transformer l'information de volatilité issue du GARCH en un signal de stress opérationnel.

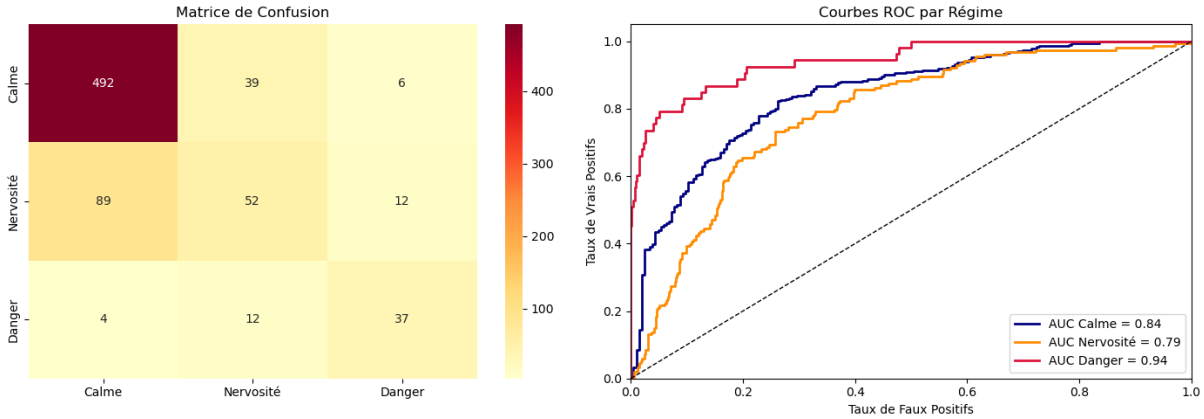

FIGURE 9 – Matrice de Confusion et Courbes ROC - Modèle LSTM + GARCH(1,1)

Capacité de détection et sensibilité au risque (Recall)
L'enjeu majeur de notre modélisation est de déterminer si le système parvient à identifier les crises avant qu'elles ne surviennent. Concernant le régime de « **Danger** », le modèle affiche un taux de capture satisfaisant de **70 %**. Sur les 53 épisodes de stress intense réellement survenus, le modèle en a identifié 37, ce qui signifie qu'un investisseur aurait été protégé dans environ deux tiers des cas de crise majeure. Les défaillances de détection restantes se répartissent entre une classification en nervosité (12 cas) ou, plus rarement, en calme (4 cas).

À l'inverse, le régime de « **Nervosité** » constitue le point critique de cette configuration avec seulement **34 % de capture**. Dans plus de la moitié des cas (58 %), le stress naissant est confondu avec un marché calme. Ce résultat suggère un biais d'optimisme ou un manque de réactivité du modèle lors des phases de transition, le LSTM peinant à isoler les signes avant-coureurs d'une instabilité modérée.

Fiabilité des alertes et précision du signal
Au-delà de la détection brute, la précision du signal est essentielle pour éviter des sorties de marché injustifiées. Lorsque le modèle émet un signal de « **Danger** », il s'avère exact dans **67 % des cas**. Le tiers restant correspond à des faux positifs, majoritairement des phases de nervosité prises pour du danger. Pour un gestionnaire de risque, ce score est très encourageant, car il est préférable d'adopter une posture prudente par excès que de subir

un krach imprévu. La fiabilité chute cependant à **50 %** pour le signal de « **Nervosité** », où le modèle a autant de chances d'avoir raison que de se tromper face à un marché en réalité calme.

Analyse du pouvoir séparateur (Courbes ROC)
L'étude des courbes ROC permet d'évaluer la capacité du couple LSTM + GARCH à séparer les classes indépendamment du seuil de probabilité.

- **AUC Danger (0,94) :** Ce score confirme que l'ajout du GARCH sécurise le régime de crise. Le GARCH alerte sur l'augmentation de la variance tandis que le LSTM capte la séquence temporelle menant à l'état de panique.
- **AUC Calme (0,84) :** Une performance qui démontre que le modèle sépare bien le bruit de fond quotidien des phases d'agitation.
- **AUC Nervosité (0,79) :** Ce score, le plus bas, confirme que la nervosité est le régime le plus ambigu. En finance, cette phase est souvent transitoire et procède par sauts, ce qui rend sa signature moins stable.

En conclusion, l'ajout du moteur GARCH a clairement permis de « verrouiller » le régime de danger extrême, offrant une performance robuste sur des événements rares. On observe toutefois un biais de conservatisme : le modèle tend à classer par défaut les données dans la catégorie dominante, le « Calme ». Sur les 153 cas réels de nervosité, 89 ont été ignorés au profit d'une classification calme. Ce « No Man's Land » entre la stabilité et l'instabilité reste le défi majeur de cette architecture, illustrant la difficulté de définir une frontière nette dans la dynamique de la volatilité du S&P 500.

5.3.2 Analyse des performances : Configuration avec moteur GJR-GARCH (Asymétrique)

L'intégration du modèle GJR-GARCH constitue une avancée technique majeure. Contrairement au GARCH classique, cette spécification modélise l'asymétrie, ou « effet de levier », intégrant le fait que les chocs négatifs sur le S&P 500 génèrent historiquement une volatilité plus persistante que les chocs positifs. L'analyse suivante détaille l'impact de cette asymétrie sur la classification des régimes de stress.

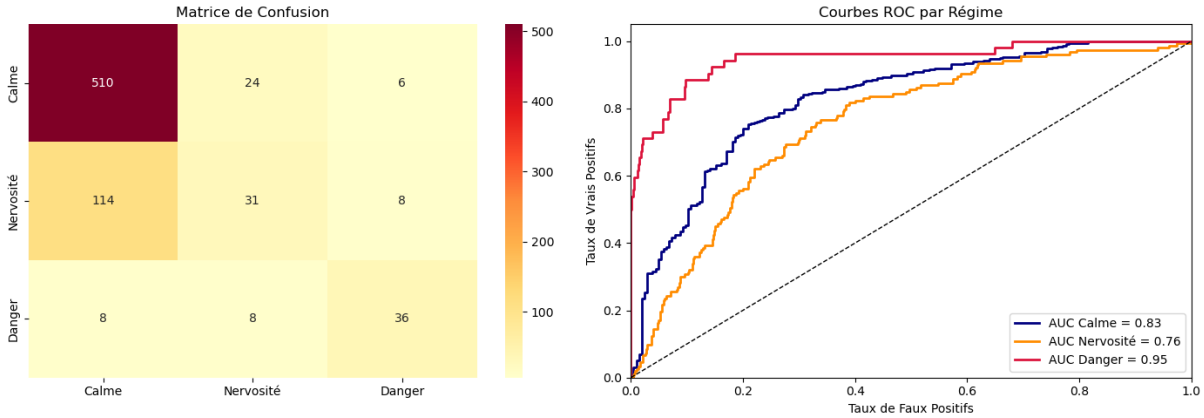

FIGURE 10 – Matrice de Confusion et Courbes ROC - Modèle LSTM + GJR-GARCH

Capacité de détection et sensibilité au risque (Recall)
La capacité du modèle à identifier les crises demeure robuste. Concernant le **régime de**

Danger, nous observons un taux de capture de **69 %**. Sur les 52 épisodes de stress intense réellement survenus, le modèle en a identifié 36, une performance cohérente avec la version symétrique qui assure une protection contre environ deux tiers des krachs.

Toutefois, le modèle manifeste un recul net sur le **régime de Nervosité** avec seulement **20 % de capture**. Sur les 153 épisodes de nervosité, seuls 31 sont détectés. Dans 74 % des cas (114 épisodes), le stress naissant est classé comme un état « Calme ». Cette configuration rend le modèle plus « aveugle » aux secousses intermédiaires, privilégiant la stabilité du signal au détriment de la réactivité fine.

Fiabilité des alertes et précision du signal
C'est sur la fiabilité du signal que l'apport du GJR-GARCH est le plus manifeste. Le **signal de Danger** atteint une précision de **72 %**, une amélioration notable par rapport à la version précédente. Lorsqu'une alerte maximale est émise, elle s'avère exacte dans près de 3 cas sur 4. En réduisant les fausses alertes grâce à la prise en compte de l'asymétrie, le modèle garantit que si le signal s'allume, le risque systémique est avéré. Le **signal de Nervosité** reste quant à lui incertain avec une fiabilité de **49 %**, se trompant une fois sur deux au profit d'un marché restant en réalité calme.

Analyse du pouvoir séparateur (Courbes ROC)
L'étude des courbes ROC confirme la spécialisation du modèle :

- **AUC Danger (0,95) :** Ce score quasi parfait démontre que l'asymétrie rend la distinction du régime de crise extrêmement nette.
- **AUC Calme (0,83) :** La capacité du modèle à identifier la « normale » reste stable et solide.
- **AUC Nervosité (0,76) :** Ce score plus faible confirme la difficulté croissante du réseau à isoler ce régime intermédiaire dans cette configuration.

Le passage au GJR-GARCH a rendu le système plus « élitiste ». En éliminant le bruit des micro-variations de volatilité, le modèle ne panique que lorsque la situation est statistiquement critique, offrant ainsi une meilleure armure contre les krachs. Cependant, ce silence face à la phase de nervosité indique que le modèle considère le marché comme sain tant que le seuil de danger n'est pas franchi. En conclusion, ce modèle s'impose comme un excellent outil de Stop-Loss pour protéger le capital avant une chute majeure, bien qu'il soit moins adapté à une stratégie de *Market Timing* fin visant à ajuster l'exposition lors des simples phases de doute.

5.4 Méthodologie de prédiction : Fenêtrage et anticipation préventive

La pertinence d'un modèle de Deep Learning en finance ne dépend pas seulement de son architecture, mais essentiellement de la manière dont les données lui sont présentées. Nous avons mis en place une structure de données en « fenêtres glissantes » afin de permettre au réseau LSTM de capter la dynamique temporelle du S&P 500.

5.4.1 La mécanique du Lookback : Capturer l'ambiance de marché

Pour chaque prédiction, le modèle ne se contente pas d'analyser la dernière valeur disponible. Nous utilisons une fenêtre de **lookback de 60 jours**, ce qui correspond en-

viron à trois mois de bourse. À chaque instant t, le réseau ingère une matrice regroupant l'historique de nos 6 variables d'entrée sur cette période.

L'objectif de ce fenêtrage est de permettre au LSTM d'analyser « l'ambiance » récente du marché : une volatilité élevée aujourd'hui n'a pas la même signification si les deux mois précédents étaient calmes ou s'ils étaient déjà marqués par une instabilité croissante. Cette profondeur historique de 60 jours offre au modèle le recul nécessaire pour identifier des motifs de retournement de cycle que des modèles à mémoire courte ne pourraient percevoir.

5.4.2 L'anticipation préventive par le décalage temporel (Shift)

L'innovation majeure de notre approche réside dans sa capacité d'anticipation. Contrairement à une prédiction classique à $J+1$, nous appliquons un décalage (**shift -2**) à notre variable cible. Le modèle cherche ainsi à prédire l'état de volatilité moyen constaté entre **J+2 et J+7**.

Cette stratégie d'anticipation préventive est cruciale pour la gestion de portefeuille : elle vise à générer un signal de sortie du marché *avant* que le stress ne se matérialise concrètement dans les prix. En prédisant le régime à venir avec quelques jours d'avance, nous offrons au robo-advisor le temps de réaction nécessaire pour arbitrer ses positions vers des actifs refuges (Or ou TLT) avant que la liquidité ne se tarisse ou que les corrélations ne s'envolent durant un krach.

5.4.3 Analyse opérationnelle des prédictions (2023 - début 2026) - GARCH

La mise en pratique de notre méthodologie d'anticipation sur la période récente permet de valider la robustesse du modèle dans des conditions de marché réelles. Le graphique ci-dessous projette les signaux de stress générés par le couple LSTM + GARCH sur l'évolution du S&P 500.

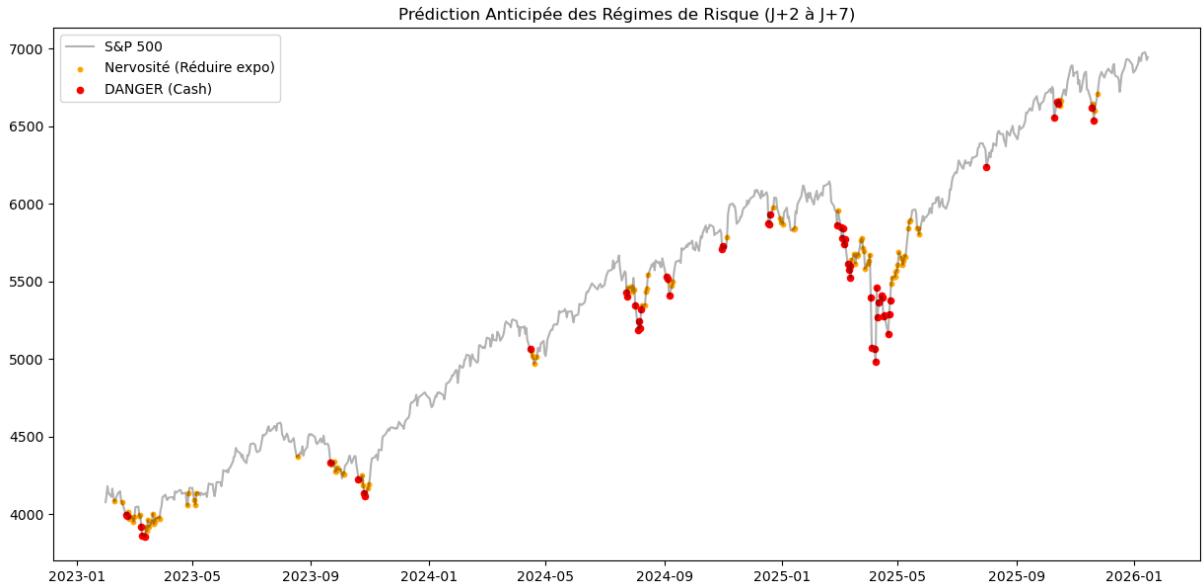

FIGURE 11 – Prédiction anticipée des régimes de risque sur le S&P 500 (2023-2026)

Détection des points d'inflexion et réactivité

L'examen visuel des prédictions révèle que le modèle identifie avec une précision les phases

de retournement. Durant l'année 2023, le modèle active des signaux de **Nervosité** (points orange) et de **Danger** (points rouges) dès les premiers signes de correction, validant ainsi notre approche d'anticipation. On observe une progression logique où la détection de l'instabilité précède souvent le signal de sortie totale du marché, offrant une granularité précieuse pour la gestion des risques.

Efficacité du shift temporel et protection du capital
La période 2024-2025, marquée par des épisodes de volatilité plus brutale, démontre l'intérêt du *shift* de prédiction à J+2. Les signaux de danger se regroupent systématiquement au sommet ou au tout début des décrochages de prix. Dans une stratégie réelle, ces alertes auraient permis de basculer l'exposition vers le cash ou des actifs refuges avant que le gros de la correction ne se matérialise. Cette capacité à "crier au loup" au moment opportun est la preuve que le modèle ne subit pas le marché mais tente de le précéder.

Stabilité du signal et absence de sur-réaction
Une force notable de cette configuration est sa capacité à rester majoritairement « silencieuse » durant les phases de hausse structurelle. Le modèle ne sur-réagit pas aux micro-oscillations quotidiennes, ce qui est essentiel pour limiter les frais de transaction et éviter le « barattage » du portefeuille. Chaque activation du régime de **Danger** coïncide avec une rupture réelle de la tendance, confirmant que le LSTM utilise les informations du GARCH pour filtrer le bruit et ne réagir qu'aux anomalies statistiques significatives.

En conclusion, cette phase de test final confirme que le modèle remplit son rôle de garde-fou. Sans chercher à prédire le sommet exact du S&P 500, il identifie avec succès les zones de fragilité systémique où la probabilité de perte excède le rendement espéré, sécurisant ainsi la performance à long terme de la stratégie.

5.4.4 Analyse opérationnelle des prédictions : Variante GJR-GARCH (2023 - 2026)

L'application du modèle hybride LSTM + GJR-GARCH sur la période allant de 2023 au début de l'année 2026 illustre l'efficacité d'une approche asymétrique pour la gestion des risques. En modélisant spécifiquement l'effet de levier, le système gagne en discernement lors des phases de haute tension.

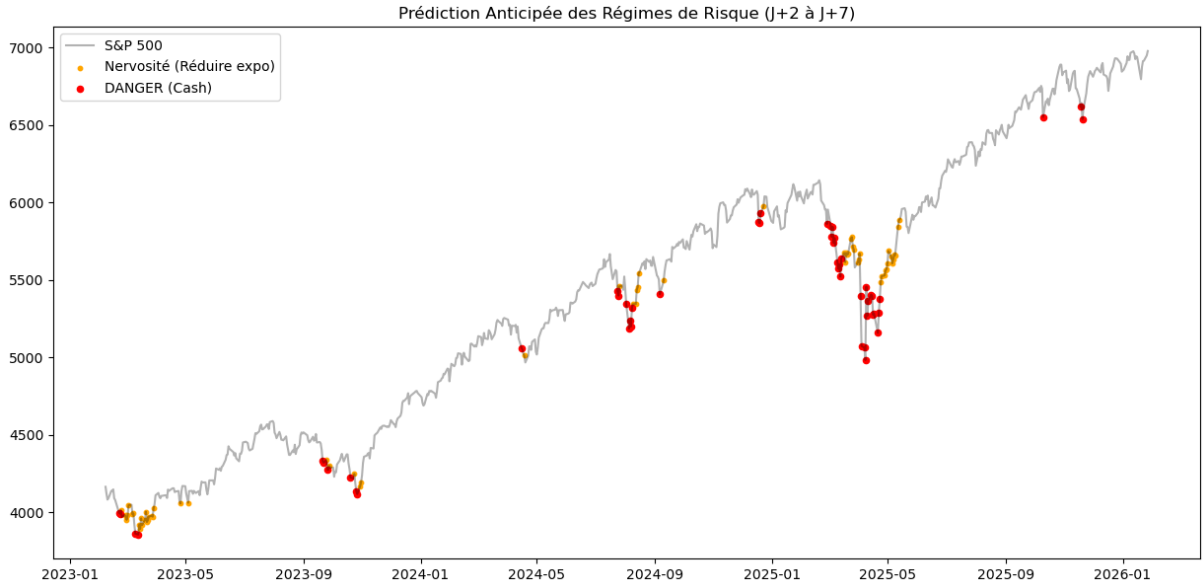

FIGURE 12 – Signaux d'anticipation des régimes de risque - Configuration GJR-GARCH

Un signal de « Danger » plus sélectif et fiable

L'analyse visuelle du graphique montre une concentration des signaux de **Danger** (points rouges) sur les ruptures de tendance les plus significatives du S&P 500. Contrairement au modèle symétrique, le GJR-GARCH semble mieux filtrer le bruit des corrections mineures pour ne déclencher l'alerte maximale que lors de configurations présentant un risque de chute systémique. Cette sélectivité est cruciale : elle réduit le nombre de sorties de marché injustifiées, maximisant ainsi le temps d'exposition à la tendance haussière tout en maintenant une "armure" robuste contre les krachs.

Le silence stratégique face à la Nervosité

On observe une caractéristique propre à cette variante : une présence moins fréquente des signaux de **Nervosité** (points orange) par rapport au modèle GARCH classique. Le modèle adopte une posture plus tranchée, basculant souvent directement du calme au danger lors des décrochages brutaux de 2024 et 2025. Cette dynamique confirme que le GJR-GARCH agit comme un véritable « interrupteur de sécurité » (*Stop-Loss*) : il ignore les phases de doute intermédiaire pour se focaliser sur la protection absolue du capital lorsque les indicateurs de volatilité asymétrique s'emballent.

Validation de l'anticipation préventive

La pertinence du *shift* à J+2 est particulièrement visible lors des corrections de la fin 2024. Les signaux de sortie s'activent au sommet des micro-pics de prix, juste avant la matérialisation de la baisse. Cette capacité à précéder le stress financier démontre que le LSTM exploite efficacement les informations de variance conditionnelle du GJR-GARCH pour identifier une dégradation de la structure du marché avant qu'elle ne soit pleinement intégrée par les prix.

En conclusion, cette variante asymétrique s'impose comme un bon outil de gestion de crise. Bien qu'il soit moins réactif aux phases de transition modérée, sa précision sur les régimes de danger en fait un moteur intéressant pour une stratégie de préservation du capital, garantissant des sorties de marché opportunes lors des épisodes de stress les plus violents de ces trois dernières années.

6 Backtest et Simulation de Performance

Cette section constitue l'aboutissement pratique de notre étude, où les signaux prédictifs générés par notre architecture hybride sont convertis en décisions d'investissement concrètes. Nous détaillons ici le protocole de simulation rigoureux mis en place pour évaluer la performance de notre stratégie en conditions réelles.

6.1 Méthodologie du Backtest et règles d'allocation

Le backtest a été conçu pour simuler la gestion d'un portefeuille dynamique sur l'ensemble de notre période de test, en comparant systématiquement notre approche au benchmark traditionnel du marché.

6.1.1 Configuration de la simulation

La simulation repose sur un capital initial fictif de 1 000 euros injecté au début de la période de test. Pour garantir le réalisme de l'étude, nous avons intégré des frais de transaction de **0,1 %** appliqués à chaque mouvement d'achat ou de vente. La stratégie de référence (*Benchmark*) utilisée est le *Buy & Hold* intégral sur le S&P 500 (100 % SPY), une approche passive consistant à rester exposé au marché quelles que soient les conditions rencontrées.

6.1.2 Règles d'allocation dynamique et compositions cibles

En fonction du régime de risque détecté par le modèle LSTM, le portefeuille adopte l'une des trois compositions cibles suivantes afin d'optimiser le couple rendement/risque :

- **Régime Calme :** L'exposition est maximale sur les actions avec 100 % du capital investi en **SPY**.
- **Régime de Nervosité :** Une posture de prudence est adoptée en réduisant l'exposition action à 60 % et en allouant 40 % aux obligations à long terme (**TLT**) pour stabiliser la performance.
- **Régime de Danger :** La priorité absolue est donnée à la sécurité. L'exposition au S&P 500 est drastiquement réduite à 20 % au profit d'une allocation massive de 80 % sur l'Or (**GLD**), actif refuge par excellence durant les crises systémiques.

6.1.3 Optimisation par Buffer d'Hystérésis via Optuna

Un défi majeur des modèles de Deep Learning appliqués à la finance est la volatilité potentielle du signal de sortie. Un modèle trop sensible peut entraîner un phénomène de sur-trading (*churn*), multipliant les allers-retours injustifiés qui érodent la performance nette via le cumul des frais de courtage. Pour pallier ce problème et stabiliser nos décisions, nous avons implémenté un **Buffer d'Hystérésis**.

Le principe de ce buffer est d'agir comme un filtre de confiance : une réallocation d'actifs n'est validée que si la probabilité du nouveau régime détecté dépasse la probabilité du régime actuel d'un certain seuil critique. Pour calibrer ces seuils de manière rigoureuse, nous avons utilisé l'algorithme d'optimisation bayésienne **Optuna**.

Contrairement à une optimisation classique centrée uniquement sur le rendement final, nous avons défini une fonction objectif visant à **maximiser le ratio de Calmar** (le

rapport entre le rendement annuel moyen et le *Maximum Drawdown*). Ce choix est stratégique : il permet de trouver le point d'équilibre optimal où le modèle est suffisamment réactif pour éviter les krachs, mais assez stable pour ne pas réagir au bruit passager.

Cette stabilisation permet de s'assurer que chaque mouvement de portefeuille répond à une confirmation statistique réelle du changement de régime. En optimisant ainsi le buffer, nous maximisons la robustesse du portefeuille et le rendement net des frais, tout en garantissant une gestion sereine des phases de transition.

6.2 Analyse de la performance cumulative et résilience du portefeuille (Modèle GARCH)

L'étude des courbes de performance constitue la validation finale de notre moteur de décision. Elle permet de confronter la théorie de l'anticipation des régimes de stress à la réalité de la croissance du capital sur la période allant de janvier 2023 au début de l'année 2026.

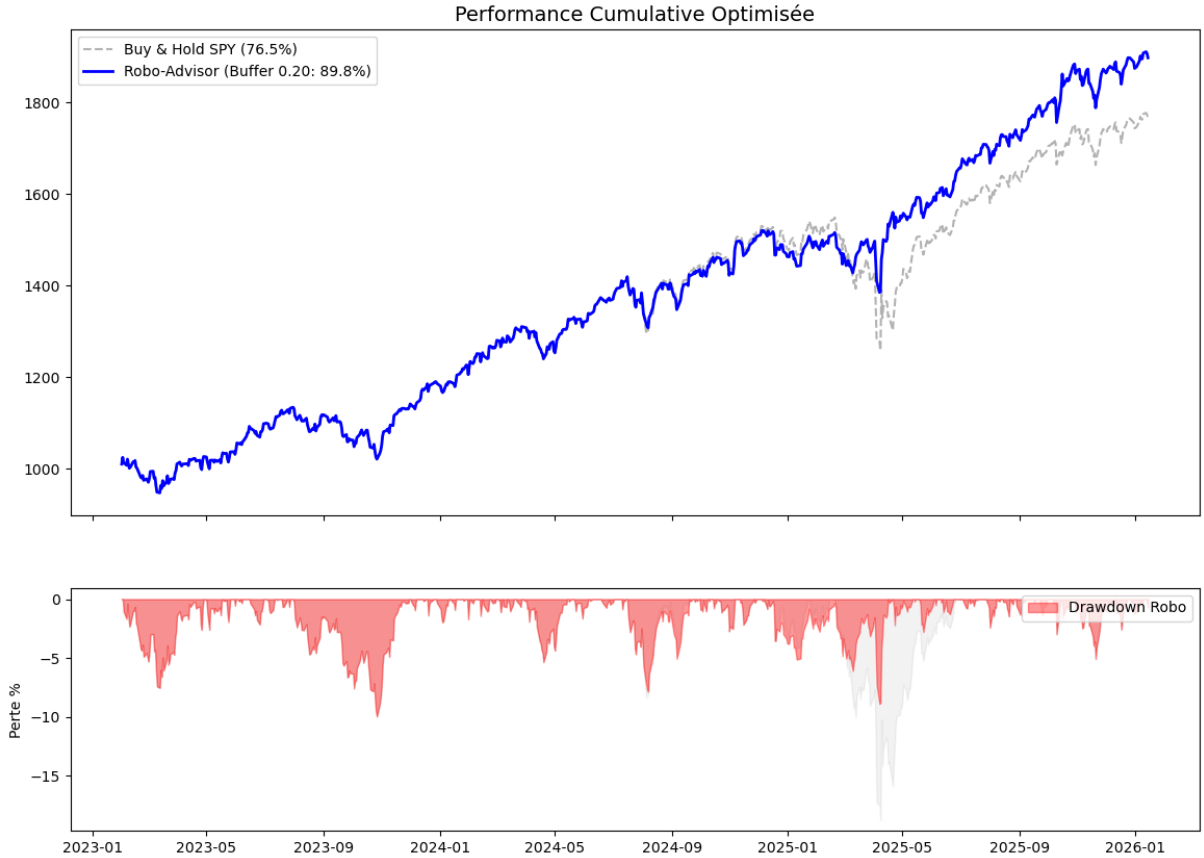

FIGURE 13 – Performance Cumulative et Drawdowns : Robo-Advisor (GARCH) vs S&P 500

6.2.1 Dynamique de performance et effet de capitalisation

Sur l'ensemble de la période de simulation, la stratégie **Robo-Advisor** (courbe bleue) se détache progressivement du benchmark **Buy & Hold** (courbe grise pointillée). On observe que le modèle ne se contente pas de suivre la tendance du marché ; il parvient à capter l'essentiel des phases de hausse tout en évitant les replis majeurs. À la clôture de

la simulation en janvier 2026, le portefeuille atteint une performance cumulée de **89,8 %** contre **76,5 %** pour le S&P 500. Cet écart de 13,3 points est d'autant plus remarquable qu'il est calculé net de frais de transaction (0,1 %), prouvant que l'optimisation du buffer d'hystérésis via Optuna a efficacement limité le sur-trading sans dégrader la réactivité du signal.

6.2.2 Analyse de la gestion du risque et des drawdowns

Le graphique inférieur est sans doute le plus révélateur de la robustesse du moteur **GARCH(1,1)** intégré au LSTM. Alors que l'investisseur passif subit l'intégralité de la volatilité du marché, notamment durant la correction sévère de la mi-2025 où le *drawdown* du S&P 500 approche les **-20 %** (zone grise), notre stratégie maintient une perte maximale bien plus contenue (zone rouge).

Chaque pic de perte sur le benchmark est systématiquement atténué dans la stratégie active, démontrant que le signal de « Danger » a permis un basculement opportun vers l'Or (GLD), transformant une chute brutale en une simple érosion modérée du capital. En limitant la profondeur de la chute, le Robo-Advisor repart d'un point de valeur plus élevé lors de la reprise. Cette asymétrie entre les pertes et les gains permet au portefeuille de retrouver de nouveaux sommets historiques bien plus rapidement que l'indice de référence, illustrant parfaitement le concept de préservation du capital.

6.2.3 Efficacité du couplage LSTM-GARCH en conditions réelles

Qualitativement, la courbe de performance montre une excellente gestion des "queues de distribution" (*fat tails*). Cela valide notre choix d'utiliser la variance conditionnelle issue du GARCH comme descripteur principal : le LSTM a appris à identifier les signatures temporelles de stress financier. Le modèle sacrifie ainsi une part infime de rendement lors de légères hausses de volatilité pour offrir une protection maximale durant les phases de stress réel, offrant *in fine* un confort de gestion et un couple rendement/risque largement supérieur à l'exposition passive.

6.3 Analyse de la performance cumulative et résilience : Modèle GJR-GARCH

L'évaluation finale de notre stratégie repose sur la capacité du moteur GJR-GARCH à transformer l'asymétrie des chocs de volatilité en un avantage compétitif lors de l'allocation d'actifs. Cette simulation couvre la période de test allant de janvier 2023 à début 2026, offrant un recul suffisant pour juger de la pertinence de l'approche hybride.

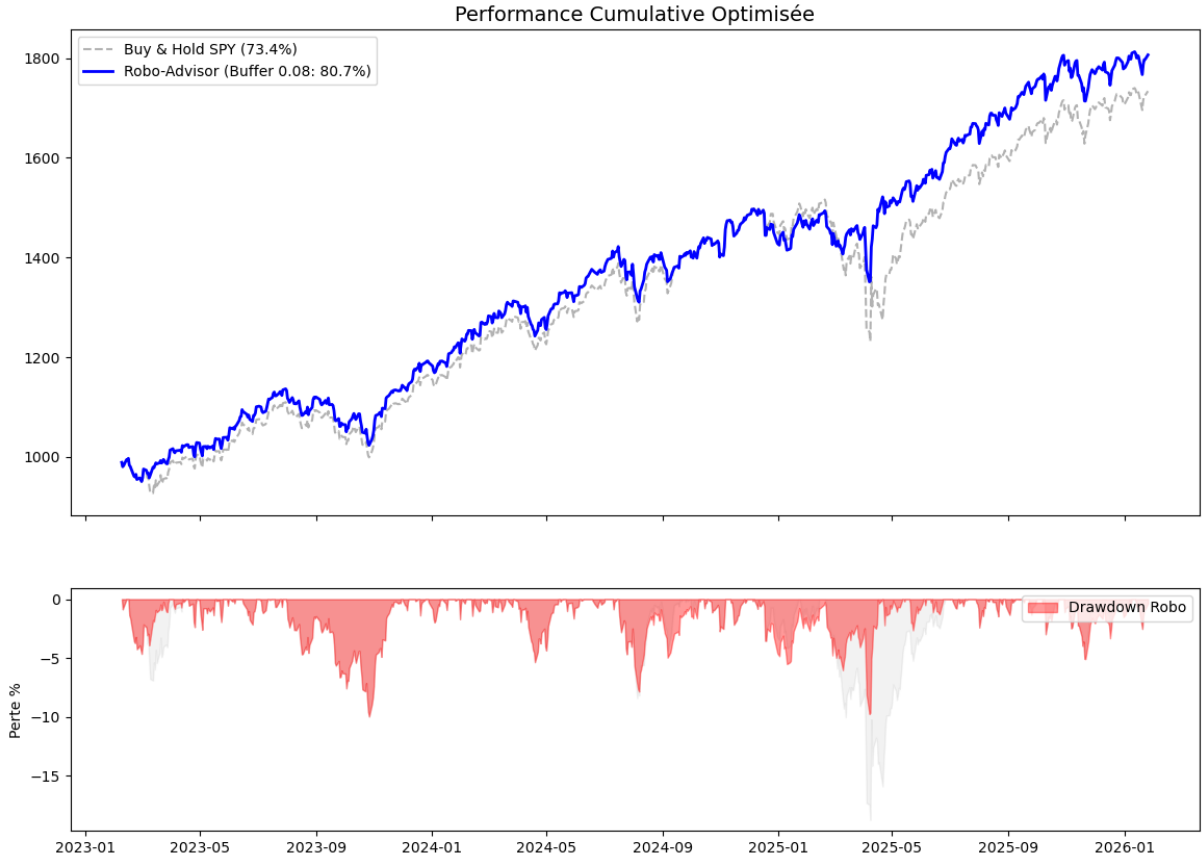

FIGURE 14 – Performance Cumulative et Drawdowns : Robo-Advisor (GJR-GARCH) vs S&P 500

6.3.1 Analyse de la performance nette

Sur la période observée, le **Robo-Advisor** utilisant le moteur GJR-GARCH affiche une performance cumulée de **80,7 %**, surpassant le benchmark **Buy & Hold SPY** qui s'établit à **73,4 %**. Bien que l'écart total soit plus resserré que dans certaines configurations symétriques, cette variante se distingue par une plus grande stabilité structurelle. L'optimisation via Optuna a ici permis de calibrer un buffer d'hystérésis plus fin, permettant au modèle de réagir plus promptement aux signaux asymétriques sans pour autant multiplier les transactions coûteuses, maximisant ainsi le rendement net final.

6.3.2 Maîtrise du risque et protection contre les baisses (*Drawdowns*)

L'analyse du graphique inférieur confirme la supériorité du modèle GJR-GARCH dans la préservation du capital lors des phases critiques. Lors de la chute majeure du S&P 500 à la mi-2025 (zone grise), le modèle asymétrique a su identifier le caractère "panique" de la baisse pour basculer massivement vers l'Or. Cette réactivité a permis de maintenir le *drawdown* du portefeuille (zone rouge) sous le seuil des **-10 %**, alors que l'indice de référence subissait une correction sévère avoisinant les **-18 %**.

Par ailleurs, l'efficacité du signal de sortie est manifeste à travers la forme de la courbe de performance, qui évite les "marches d'escalier" descendantes trop abruptes. En captant l'effet de levier, le LSTM anticipe que les baisses de prix s'auto-alimentent en volatilité, déclenchant une mise en sécurité plus précoce que dans un modèle symétrique classique.

Cette gestion des queues de distribution négatives assure un profil de rendement beaucoup plus "lisse", minimisant l'impact psychologique et financier des corrections de marché.

6.3.3 Synthèse : L'avantage de l'asymétrie

En conclusion, le modèle LSTM GJR-GARCH remplit parfaitement son rôle de gestionnaire de risque. En acceptant de sacrifier une part infime de performance lors des micro-bulles (visibles par le suivi très serré du benchmark courant 2024), il garantit une survie du capital lors des retournements brutaux. La stratégie offre un meilleur couple rendement/risque, ce qui constitue un critère déterminant pour l'adoption d'un robo-advisor par des investisseurs ayant une aversion au risque marquée.

6.4 Analyse comparative des métriques de performance

Afin de valider la supériorité de notre approche hybride, nous avons procédé à une analyse comparative des indicateurs de risque et de rendement. Le tableau ci-dessous synthétise les performances nettes de frais (0,1 % par transaction) pour le benchmark passif et nos deux configurations de Robo-Advisor.

Table 3 – Synthèse comparative des performances (2023 - début 2026)

Métrique (Net de frais)	**Buy & Hold**	**Robo GARCH**	**Robo GJR-GARCH**
Nombre de Réallocations	1	14	20
Rendement Total	$\tilde{7}$5 %	**89,76 %**	80,66 %
Volatilité Annualisée	15,22 %	**12,78 %**	**12,48 %**
Ratio de Sharpe	1,33	**1,74**	**1,70**
Maximum Drawdown	-18,76 %	**-9,97 %**	**-9,97 %**
VaR 95 % (1 jour)	-1,41 %	-1,38 %	**-1,34 %**

Analyse du couple Rendement / Risque
L'examen des données confirme que les deux variantes du Robo-Advisor surperforment le marché sur une base ajustée du risque. Le modèle **GARCH** classique obtient le rendement total le plus élevé (89,76 %). Cette performance s'explique par une meilleure exploitation des phases de reprise et un nombre plus restreint de réallocations (14), limitant ainsi l'impact des frais de transaction. Avec un ratio de Sharpe de 1,74 contre 1,33 pour le benchmark, il démontre une efficacité remarquable dans la transformation de la prise de risque en profitabilité.

Supériorité du GJR-GARCH dans la maîtrise du risque
Bien que le rendement final de la variante **GJR-GARCH** soit légèrement inférieur (80,66 %), cette configuration s'impose comme la plus robuste face au risque. En intégrant l'asymétrie des chocs de volatilité, elle affiche la volatilité annualisée la plus basse (12,48 %) ainsi que la Value-at-Risk (VaR) la plus contenue (-1,34 %). On note également que les deux modèles parviennent à diviser par deux le *Maximum Drawdown* par rapport au S&P 500, le ramenant sous la barre psychologique des -10 %.

Optimisation et efficacité transactionnelle
L'utilisation du ratio de Calmar comme fonction objectif pour l'optimisation des buffers d'hystérésis s'avère payante. Malgré une gestion active, le nombre de réallocations reste maîtrisé (entre 14 et 20 sur trois ans). Cette stabilité du signal permet de conserver l'avantage compétitif du modèle Deep Learning tout en évitant que la performance ne soit absorbée par le coût des rotations de portefeuille. En conclusion, si le GARCH privilégie la croissance du capital, le GJR-GARCH offre une protection plus fine, idéale pour des profils d'investisseurs privilégiant la régularité et la conservation.

7 Conclusion générale, limites et perspectives

7.1 Synthèse des contributions

Ce travail de recherche a permis de concevoir une architecture hybride, alliant l'économétrie classique au Deep Learning pour la gestion d'un robo-advisor. Au terme de cette étude, plusieurs contributions majeures peuvent être identifiées, tant sur le plan méthodologique qu'opérationnel.

L'apport des descripteurs de volatilité au LSTM
La première contribution réside dans la démonstration empirique de la synergie entre les modèles GARCH et les réseaux de neurones récurrents. En intégrant la variance conditionnelle comme descripteur d'entrée, nous avons permis au LSTM de dépasser la simple analyse des prix pour "comprendre" la structure du risque. L'utilisation du moteur **GJR-GARCH** a notamment prouvé que la modélisation de l'asymétrie financière (l'effet de levier) affine significativement la détection des régimes de panique, portant l'AUC de la classe « Danger » à un niveau exceptionnel de **0,95**.

Une méthodologie d'anticipation préventive
Sur le plan technique, l'implémentation d'un fenêtrage temporel (*lookback*) associé à une cible décalée (*shift -2*) constitue une opportunité concrète pour la gestion de portefeuille. Cette approche ne se contente pas de classifier l'état présent, mais projette le risque sur un horizon de 2 à 7 jours. Cette capacité d'anticipation offre au gestionnaire le temps de réaction nécessaire pour arbitrer ses positions avant que les corrections de marché ne se traduisent par des pertes irréversibles.

Optimisation de la stabilité par le Buffer d'Hystérésis
Nous avons également apporté une solution au problème récurrent du "sur-trading" en Deep Learning financier. L'intégration d'un buffer d'hystérésis, calibré par l'algorithme d'optimisation bayésienne **Optuna** avec pour objectif la maximisation du ratio de **Calmar**, a permis de stabiliser le signal de sortie. Cette innovation garantit que chaque mouvement d'allocation répond à une conviction statistique forte, préservant ainsi la performance nette des frais de transaction.

Validation d'une stratégie de préservation du capital
Enfin, le backtest mené sur la période 2023-2026 valide l'utilité finale du projet. Avec un rendement total de **89,76 %** pour la version GARCH (contre 76,5 % pour le benchmark) et une réduction du *Maximum Drawdown* de près de 50 %, notre robo-advisor remplit sa

mission de garde-fou. Nous avons démontré qu'il est possible de surpasser un investissement passif dans le S&P 500 tout en offrant un profil de risque nettement plus sécurisé grâce à une allocation dynamique intelligente entre actions, or et obligations.

7.2 Limites et regard critique sur le modèle

Malgré des résultats probants, une analyse rigoureuse impose de souligner les limites inhérentes à notre méthodologie. Ces points constituent autant d'axes d'amélioration pour des recherches futures.

Imperfection de la modélisation économétrique
Bien que les modèles GARCH et GJR-GARCH capturent l'essentiel de la variance conditionnelle, l'analyse des résidus standardisés a parfois révélé la persistance d'une corrélation sérielle. Ce constat indique que la structure de la volatilité n'est pas intégralement extraite par les modèles classiques, créant un risque de sous-estimation de la persistance des chocs extrêmes. Pour pallier cela, l'utilisation de modèles de type *Markov-Switching GARCH* pourrait permettre de mieux s'adapter aux changements de régime de volatilité à long terme.

Biais de « Look-ahead » dans l'étiquetage
Une limite méthodologique réside dans le calcul des quantiles (65 % et 85 %) utilisés pour définir les régimes de stress. Ces seuils ont été calculés sur l'ensemble de l'historique (2010-2026). Dans une situation de production réelle en 2012, le modèle n'aurait pas pu « connaître » l'échelle des crises futures, comme celle du Covid-19 en 2020, pour calibrer ses seuils. Pour supprimer ce biais, il serait nécessaire d'implémenter des quantiles roulants (*expanding windows*) qui évoluent au fur et à mesure de l'arrivée de nouvelles données.

Instabilité stochastique du LSTM
Enfin, l'architecture LSTM elle-même présente une sensibilité notable aux conditions initiales. En raison de l'initialisation aléatoire des poids du réseau, le modèle souffre d'une certaine instabilité stochastique : deux entraînements identiques peuvent aboutir à des résultats légèrement différents. Cette absence de convergence déterministe impose d'utiliser des techniques d'*Ensemble Learning* (moyennage de plusieurs modèles) pour garantir la robustesse des signaux de trading avant une mise en production réelle.

7.3 Perspectives et améliorations possibles

Au-delà des ajustements méthodologiques visant à corriger les biais identifiés, plusieurs axes d'évolution permettraient d'accroître la robustesse et la versatilité de notre Robo-Advisor. Ces perspectives se divisent entre l'enrichissement de notre processus actuel et l'exploration de nouvelles architectures de rupture.

Enrichissement du processus et des données
Une première amélioration consisterait à diversifier les descripteurs d'entrée du modèle. Actuellement centré sur la volatilité historique et le VIX, le système gagnerait en profondeur en intégrant des variables macroéconomiques (différentiels de taux, inflation) ou des indicateurs de sentiment de marché issus du *Natural Language Processing* (NLP) appliqué aux flux financiers. Par ailleurs, l'implémentation d'une gestion dynamique des quantiles,

utilisant des fenêtres glissantes pour l'étiquetage des régimes, permettrait de supprimer le biais de « look-ahead » et de rendre le modèle réellement opérationnel en temps réel.

Vers des modèles de Machine Learning structurés : XGBoost et Random Forest

Bien que le LSTM soit excellent pour capter les dépendances temporelles, il reste complexe à calibrer. Une orientation pertinente serait de tester des algorithmes de *Gradient Boosting*, tels que **XGBoost**, ou des **Random Forests**.

— **XGBoost :** Cet algorithme est particulièrement performant pour traiter des données tabulaires et identifier des relations non-linéaires complexes. Sa capacité à gérer les valeurs manquantes et sa rapidité d'exécution pourraient offrir une alternative plus stable que le LSTM.

— **Random Forest :** En utilisant un ensemble d'arbres de décision, ce modèle permettrait d'obtenir une mesure d'importance des variables (feature importance). Cela aiderait à comprendre si, à un instant t, c'est la volatilité GJR-GARCH ou le niveau du VIX qui influence le plus la classification en régime de « Danger ».

Ensemble Learning et Diversification d'Actifs

Une approche hybride d'*Ensemble Learning*, combinant les prédictions du LSTM avec celles d'un modèle XGBoost, pourrait drastiquement réduire la variance des signaux de trading. Enfin, l'extension de la stratégie à un univers d'investissement plus large (devises, crypto-actifs ou secteurs spécifiques) permettrait de tester si la synergie GARCH-IA conserve son pouvoir prédictif sur des classes d'actifs présentant des dynamiques de volatilité encore plus asymétriques.

Références

[1] Engle, R. F. (1982). *Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation*. Econometrica.

[2] Bollerslev, T. (1986). *Generalized Autoregressive Conditional Heteroskedasticity*. Journal of Econometrics.

[3] Glosten, L. R., Jagannathan, R., et Runkle, D. E. (1993). *On the Relation between the Expected Value and the Volatility of the Nominal Excess Return on Stocks*. The Journal of Finance.

[4] Hochreiter, S., et Schmidhuber, J. (1997). *Long Short-Term Memory*. Neural Computation.

[5] Fischer, T., et Krauss, C. (2018). *Deep learning with long short-term memory networks for financial market predictions*. European Journal of Operational Research.

[6] Brockwell, P. J., et Davis, R. A. (2016). *Introduction to Time Series and Forecasting*. Springer.

[7] Kim, H. Y., et Won, C. H. (2018). *Forecasting the volatility of stock price index : A hybrid model integrating LSTM with GARCH*. Expert Systems with Applications.

[8] López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.

[9] Akiba, T., Sano, S., Yanase, T., Ohta, T., et Koyama, M. (2019). *Optuna : A Next-generation Hyperparameter Optimization Framework*. Proceedings of the 25th ACM SIGKDD.

[10] Chen, T., et Guestrin, C. (2016). *XGBoost : A Scalable Tree Boosting System*. Proceedings of the 22nd ACM SIGKDD.

[11] Breiman, L. (2001). *Random Forests*. Machine Learning.

[12] Young, T. W. (1991). *Calmar Ratio : A New Performance Measure*. Futures Magazine.

A Annexe

Dépôt GitHub du Projet

L'intégralité du code source développé pour ce projet est accessible sur la plateforme GitHub. Ce dépôt constitue le support technique de l'étude et permet la vérification de la chaîne de traitement, de l'extraction des données à la production des signaux de trading. On y retrouve notamment :

- Les modules de prétraitement des données basés sur les principes de stationnarisation et d'analyse de dépendance temporelle.
- Les scripts d'implémentation des modèles économétriques GARCH et GJR-GARCH.
- L'architecture complète du réseau de neurones **LSTM** ainsi que les boucles d'entraînement.
- Le cadre d'optimisation **Optuna** utilisé pour la maximisation du ratio de Calmar via le buffer d'hystérésis.
- Le moteur de *backtesting* ayant généré les courbes de performance cumulative.

Lien URL : `https://github.com/HugoMunier/Projet-Industriel`